Job Market Skills Analytics

Навыки и зарплаты в вакансиях LinkedIn

123 849 вакансий
516.8 MB исходных данных
SQLite, Python и интерактивный анализ

Сулейманов Тагир, Дархан Зейнулла

Programming for Data Analysis and Database · Applied Artificial Intelligence

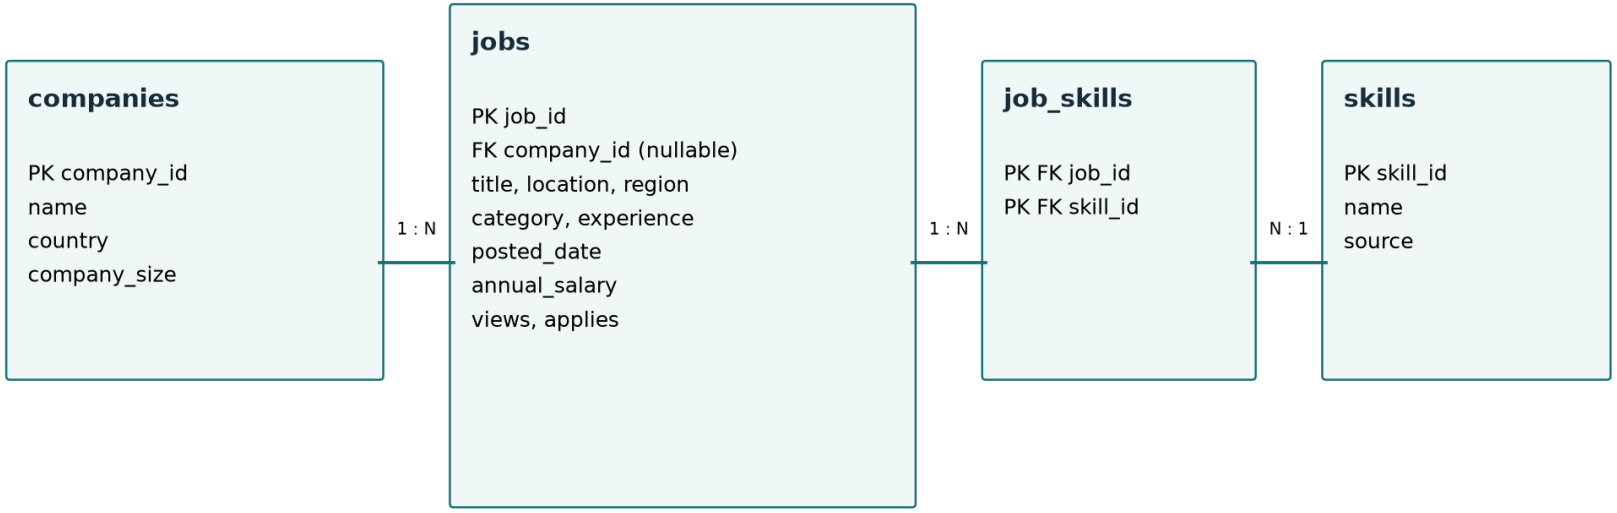
Данные и вопросы исследования

Какие навыки встречаются чаще?
Как зарплаты различаются по регионам и ролям?
Можно ли предсказать число объявлений на следующий день?

Kaggle, Arsh Koneru, версия 13
Период наблюдений: 2023-12-05 - 2024-04-20
Сопоставимая зарплата: 29.1% вакансий

https://www.kaggle.com/datasets/arshkon/linkedin-job-postings · CC BY-SA 4.0. Исторические снимки не описывают весь рынок.

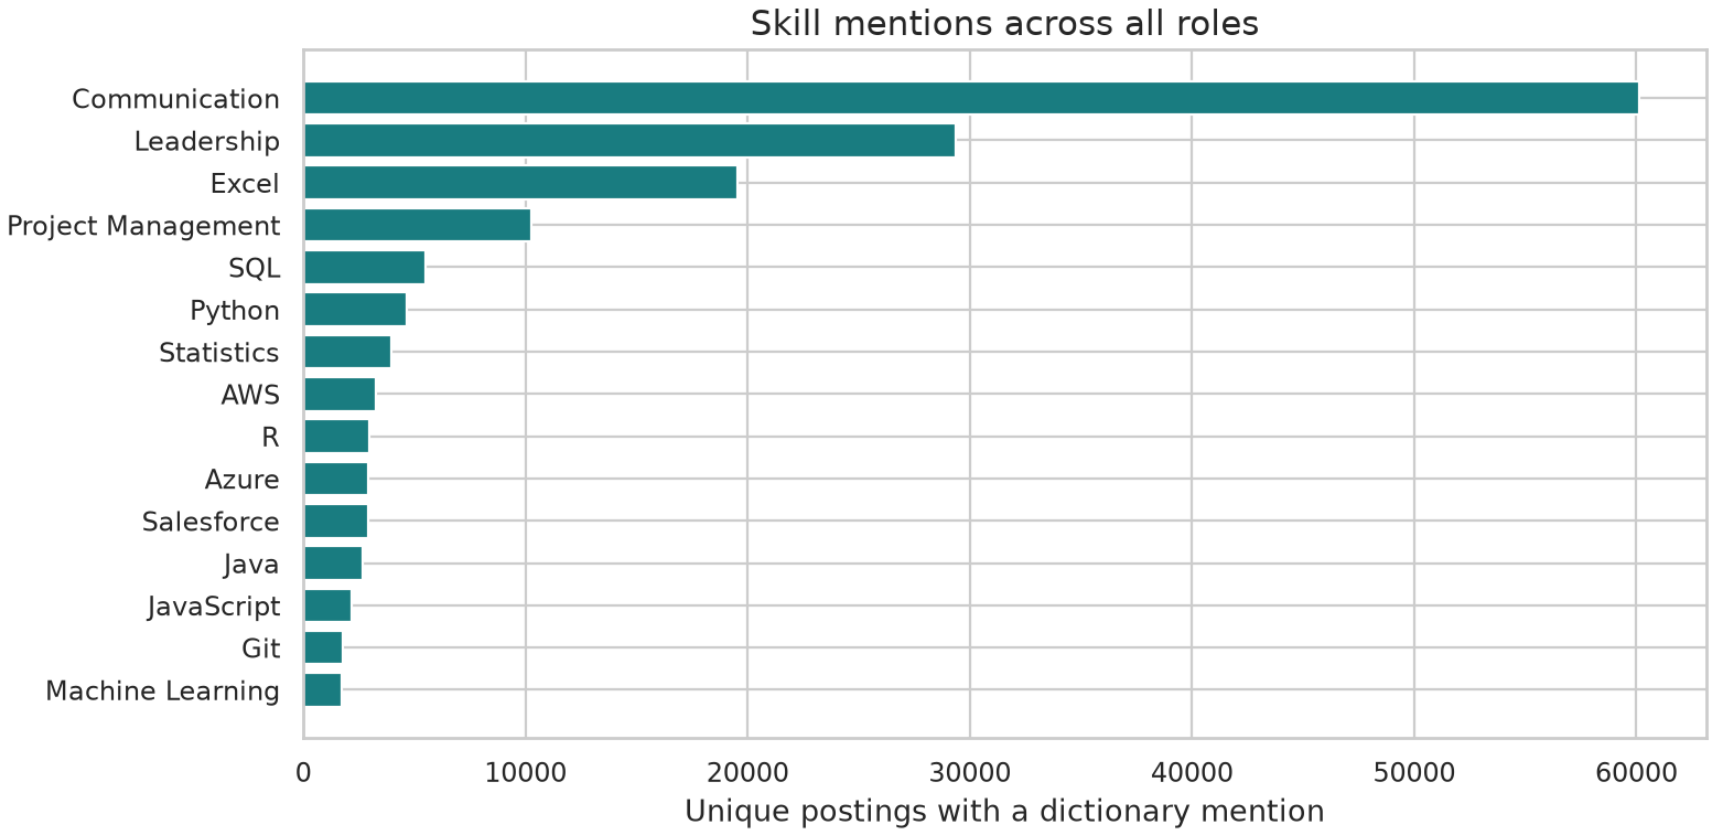
Архитектура и связи данных



CSV читается блоками по 10 000 строк.
SQLite хранит связи, Parquet - компактные признаки.
Streamlit получает данные через SQL с параметрами.

Исходный код: jobmarket/pipeline.py, sql/schema.sql. ER-диаграмма также сохранена в SVG.

Наиболее частые упоминания навыков



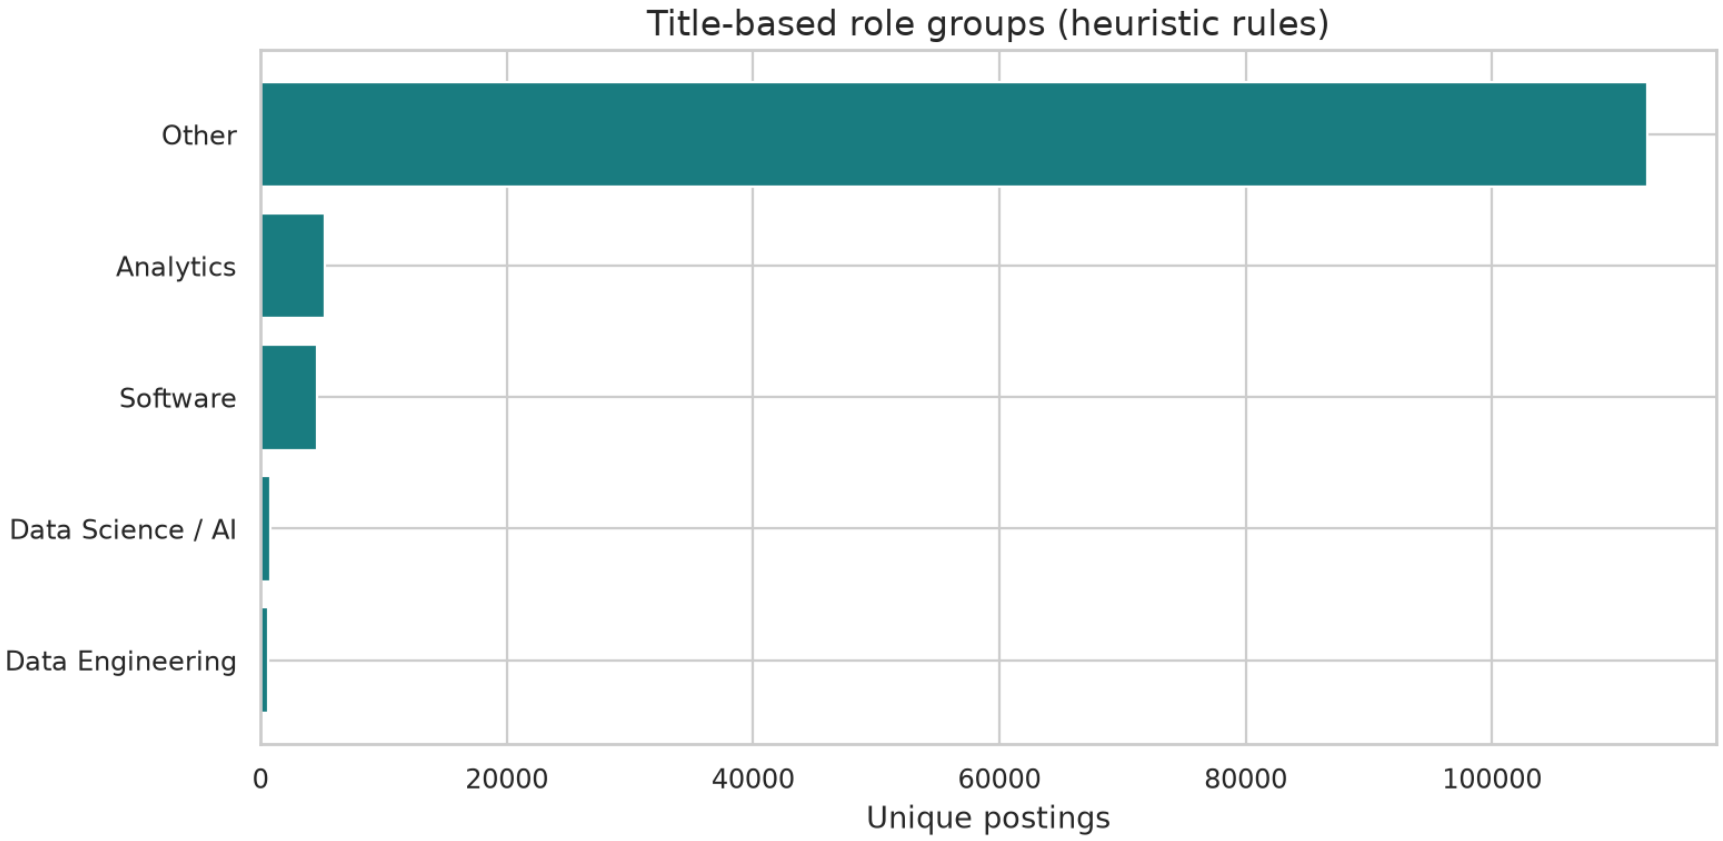
32 навыка в словаре.

Одна вакансия учитывается один раз для каждого навыка.

Категории LinkedIn показаны отдельно.

Источник: SQL 01. Упоминание слова не подтверждает обязательность требования.

Группы должностей



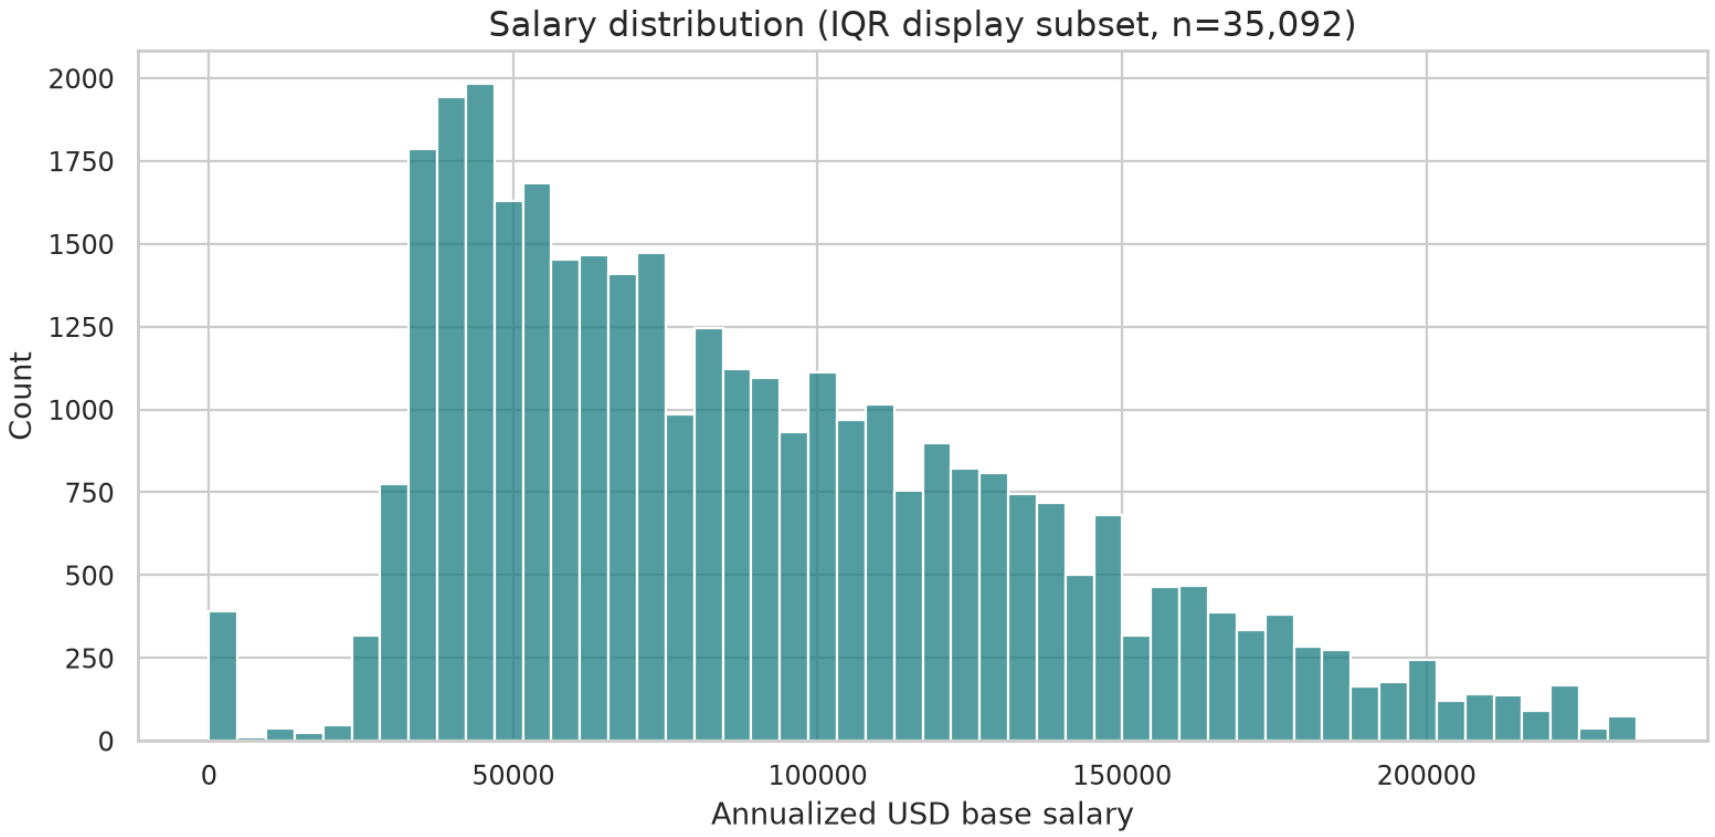
Категория определяется по названию.

Правила доступны в skills.py.

Other включает остальные профессии.

Источник: очищенная таблица jobs, title-based category. Категоризация эвристическая.

Распределение зарплат



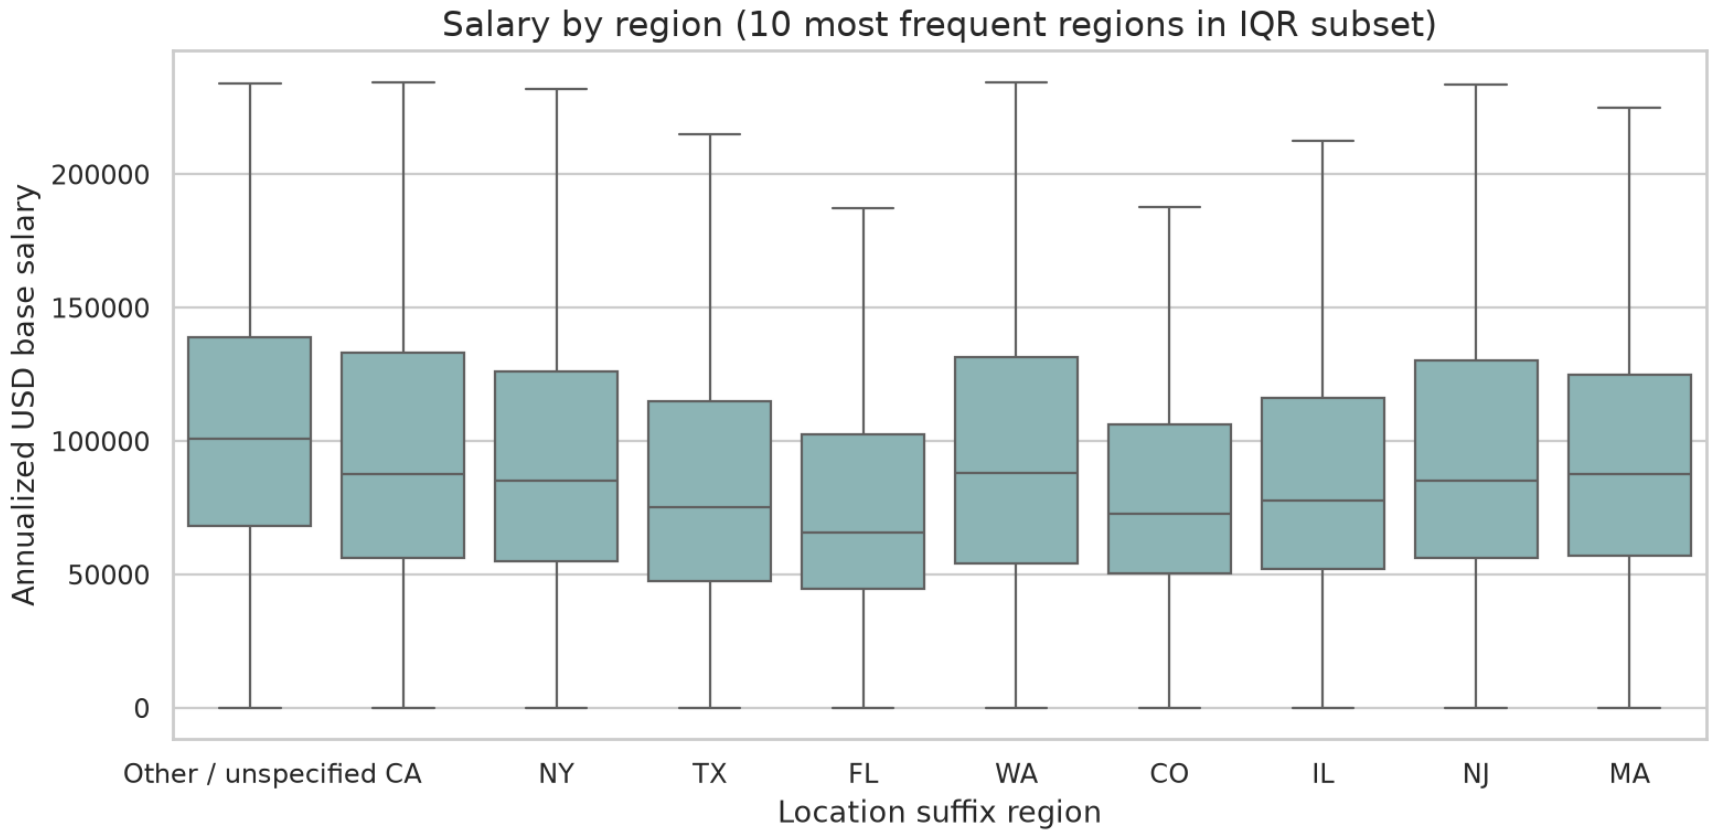
Медиана всей допустимой подвыборки **81 510 USD в год**

Покрытие 29.1%

График ограничен IQR

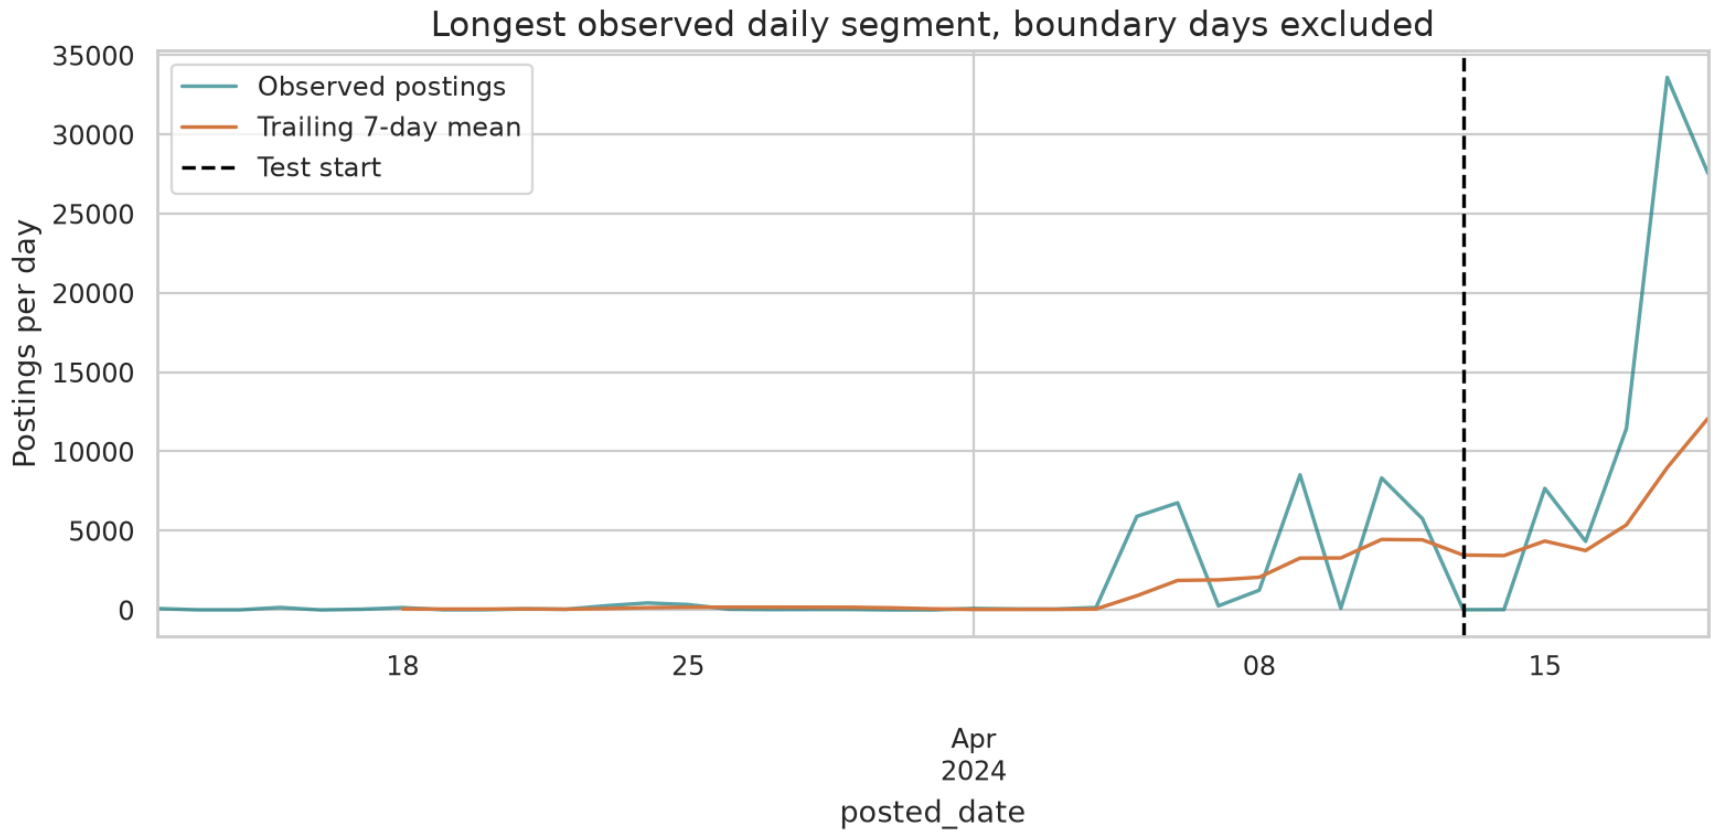
USD BASE_SALARY. Почасовая ставка × 2080. Исходные выбросы сохранены.

Региональные различия зарплат



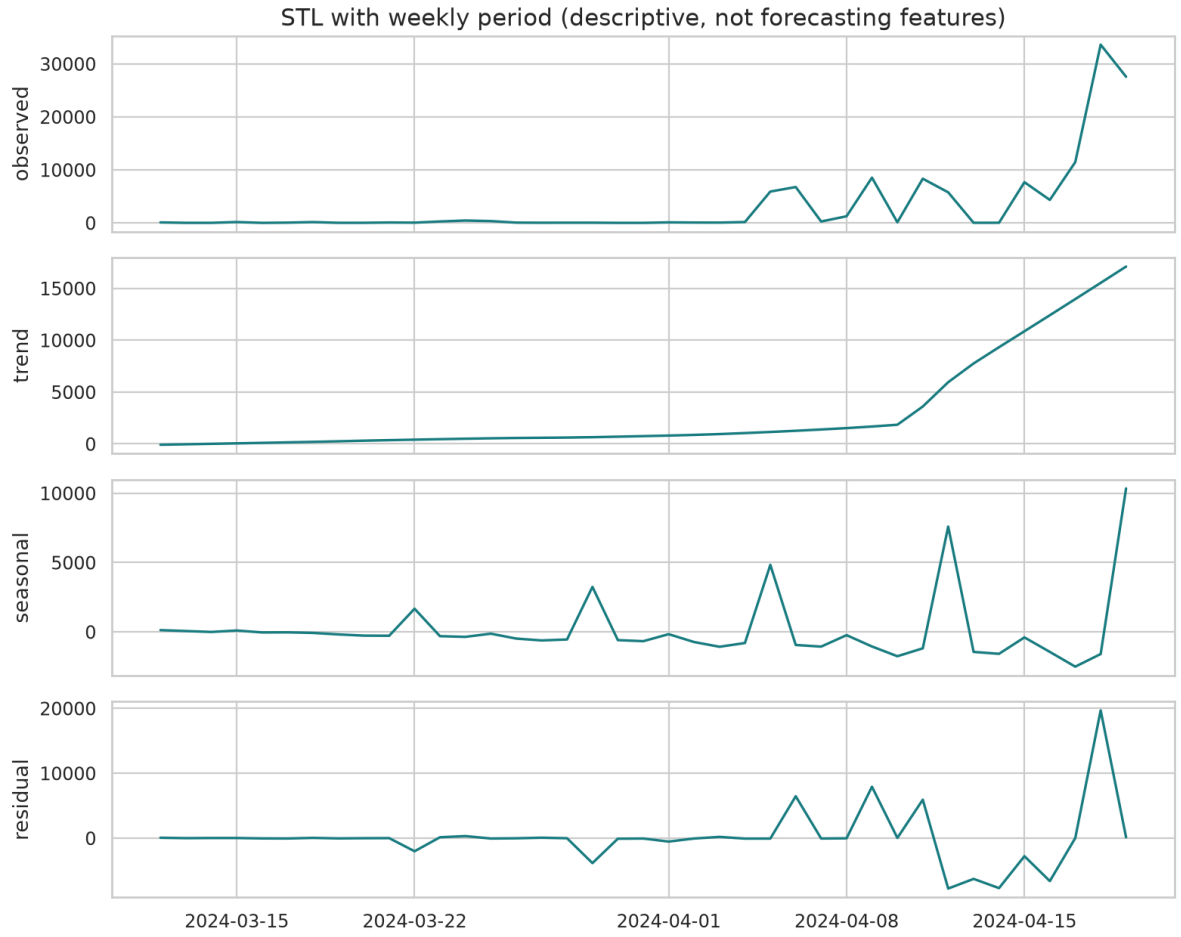
10 наиболее частых регионов IQR-подвыборки. Регион - суффикс location. Выборка зарплат неполная.

Наблюдаемые публикации во времени



Самый длинный непрерывный сегмент, граничные дни исключены. Пропуски сбора не считаются нулём.

Недельная декомпозиция STL



Период равен 7 дням.

Компоненты описывают этот сегмент.

STL не используется для признаков прогноза.

Источник: statsmodels STL, robust=True. Вывод о годовой сезонности не делается.

Baseline и два метода прогноза

Метод	MAE val	MAE test	мс	KiB
Naive	4 976.14	7 436.86	0.003	0.44
Moving average 7	3 443.53	9 516.88	0.017	1.25
Linear regression	3 518.90	9 042.52	3.412	13.33

На каждом шаге прогноз на один день.
Выбор по validation: **Moving average 7**.
На последующем тесте Naive оказался точнее.

MAE - вакансии в день. Время: медиана 5 запусков. KiB: tracemalloc, не RSS. Короткий тест ограничивает выводы.

CSV Parquet и SQLite

Подход	Секунды	Python MiB
CSV baseline	0.1903	7.83
Parquet	0.0172	2.53
SQLite + Pandas	0.2021	28.08

Одинаковые столбцы и агрегация Pandas.
Результаты совпадают с допуском 1e-8.
Форматы решают разные задачи хранения и запросов.

Медиана 3 запусков после прогрева. Кэш ОС не очищался. Память tracemalloc не включает все нативные выделения.

Основные результаты

Создан полный цикл анализа и база со связями.
10 SQL-запросов и фильтры помогают исследовать выборку.
Пропуски зарплат и сбора ограничивают обобщение.

Сопоставимая зарплата: 29.1% вакансий.
Медиана: 81 510 USD в год.
На тестовой неделе Naive точнее скользящего среднего.

Дальнейшая работа: ручная проверка извлечения навыков и более длинный непрерывный ряд.

Участники и вклад в проект

Сулейманов Тагир
Загрузка CSV блоками, проверка качества и очистка данных, пересчёт зарплат, извлечение навыков, схема SQLite, ER-диаграмма и SQL-запросы.

Дархан Зейнулла
EDA и визуализации, временные ряды и STL, сравнение прогнозов по MAE, времени и памяти, дашборд Streamlit, оформление отчёта и презентации.

Совместная работа: интеграция модулей и проверка результатов.