# Job Market Skills Analytics

Навыки и зарплаты в вакансиях LinkedIn

123 849 вакансий
516.8 MB исходных данных
SQLite, Python и интерактивный анализ

Сулейманов Тагир, Дархан Зейнулла

Programming for Data Analysis and Database · Applied Artificial Intelligence

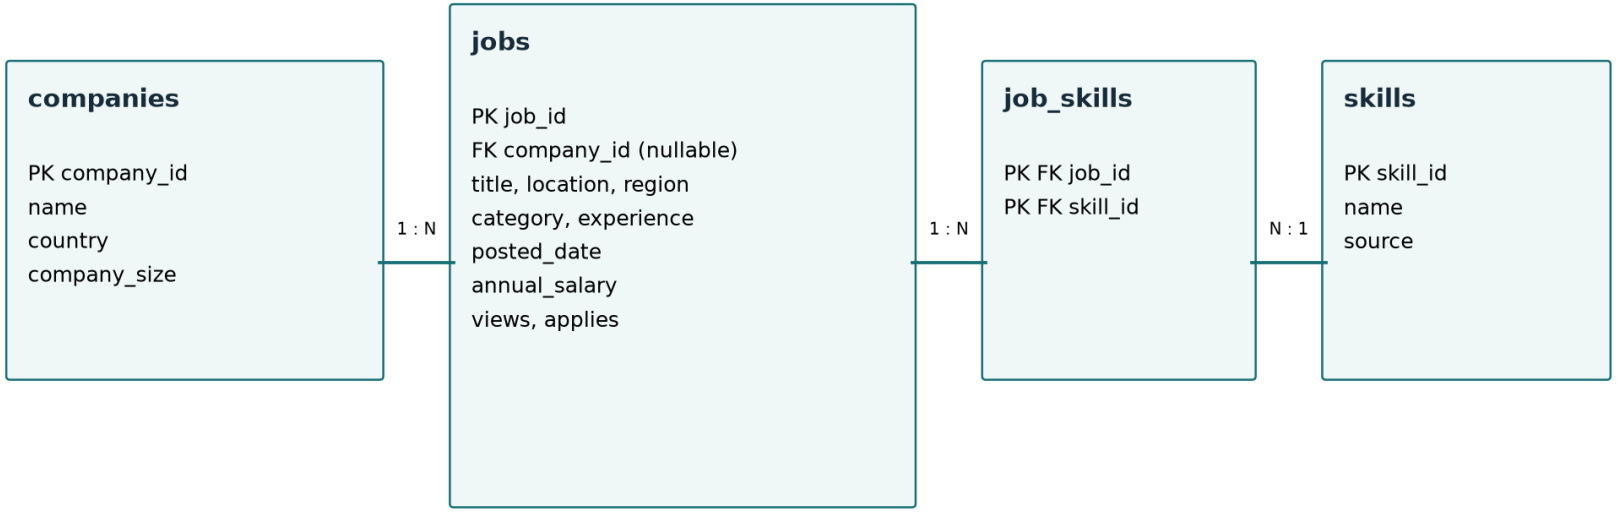
# Данные и вопросы исследования

Какие навыки встречаются чаще?
Как зарплаты различаются по регионам и ролям?
Можно ли предсказать число объявлений на следующий день?

Kaggle, Arsh Koneru, версия 13
Период наблюдений: 2023-12-05 — 2024-04-20
Сопоставимая зарплата: 29.1% вакансий

https://www.kaggle.com/datasets/arshkon/linkedin-job-postings · CC BY-SA 4.0. Исторические снимки не описывают весь рынок.

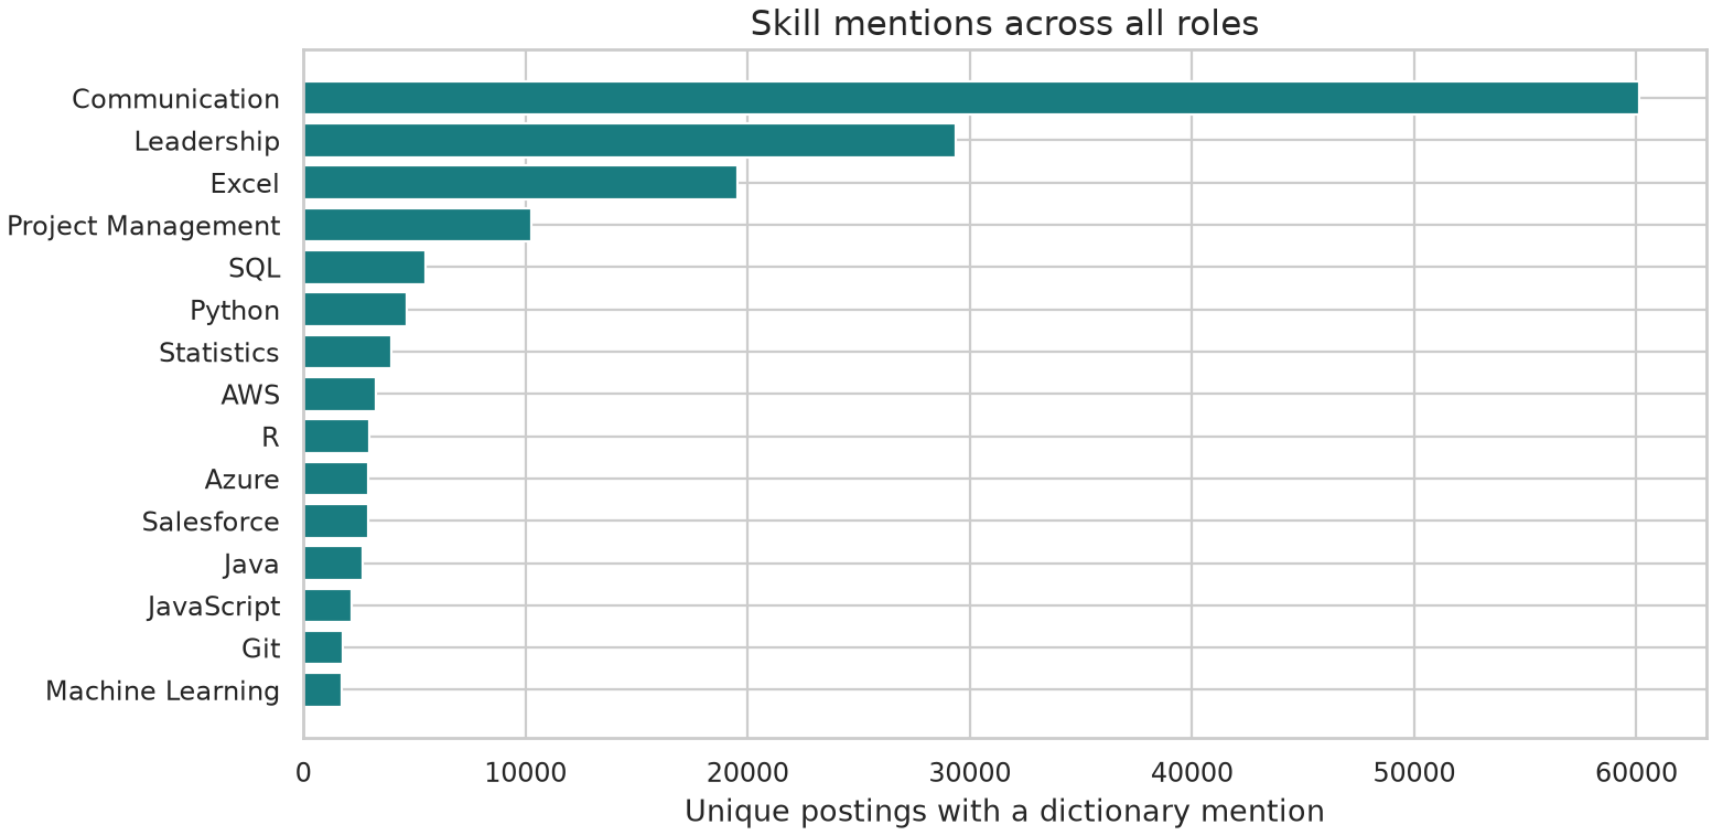
# Архитектура и связи данных




CSV читается блоками по 10 000 строк.
SQLite хранит связи, Parquet — компактные признаки.
Streamlit получает данные через SQL с параметрами.

Исходный код: jobmarket/pipeline.py, sql/schema.sql. ER-диаграмма также сохранена в SVG.

# Наиболее частые упоминания навыков



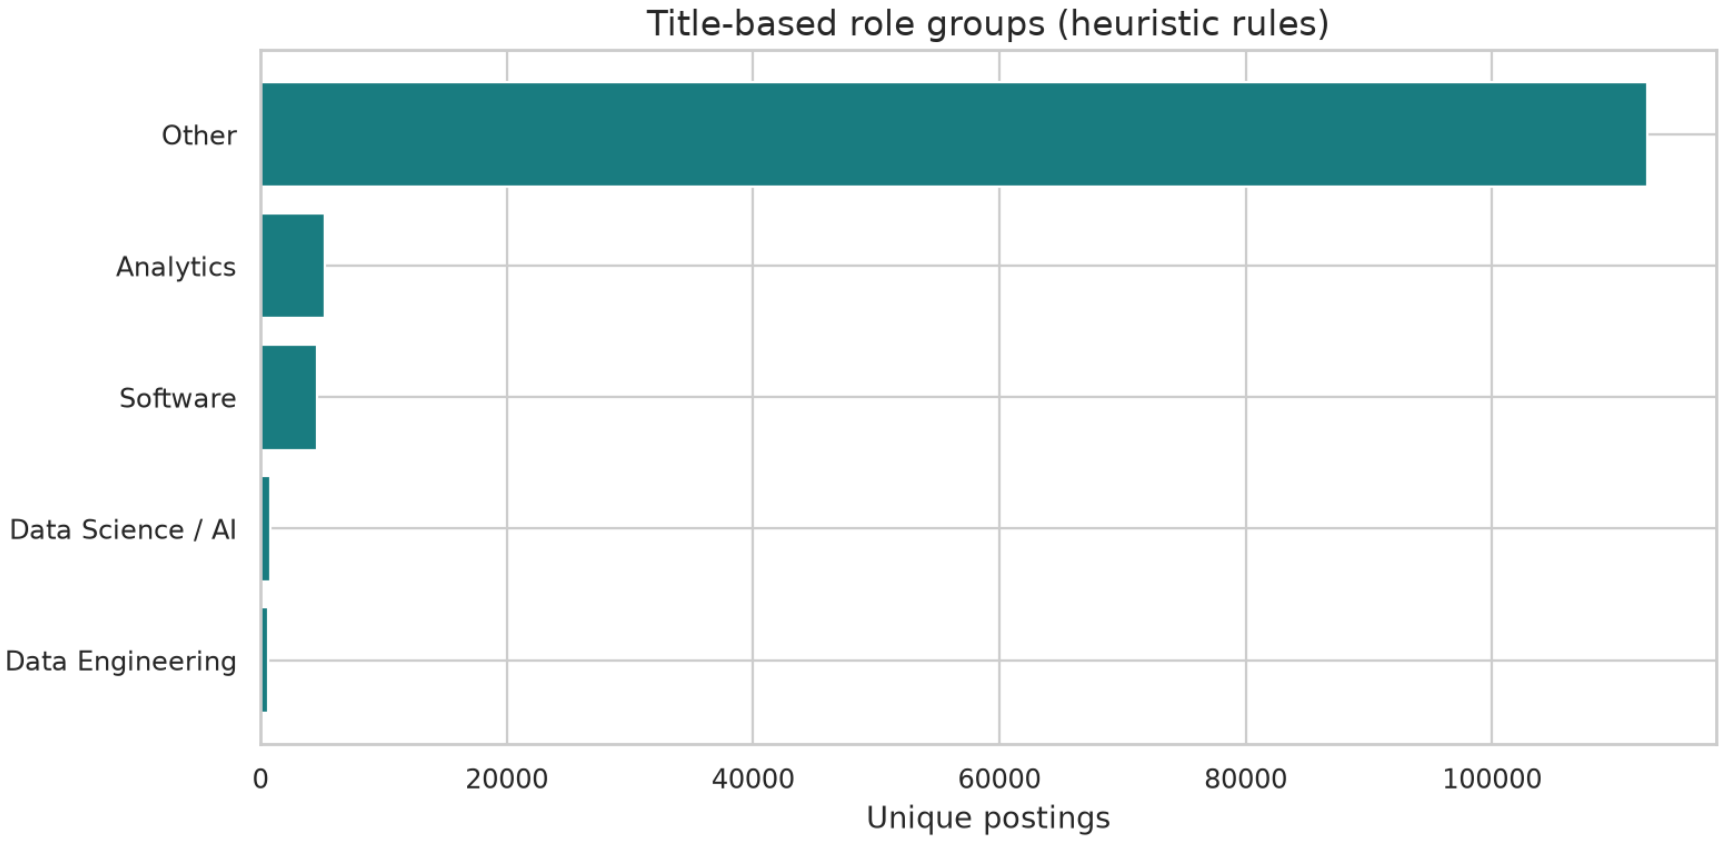

32 навыка в словаре.

Одна вакансия учитывается один раз для каждого навыка.

Категории LinkedIn показаны отдельно.

Источник: SQL 01. Упоминание слова не подтверждает обязательность требования.

# Группы должностей



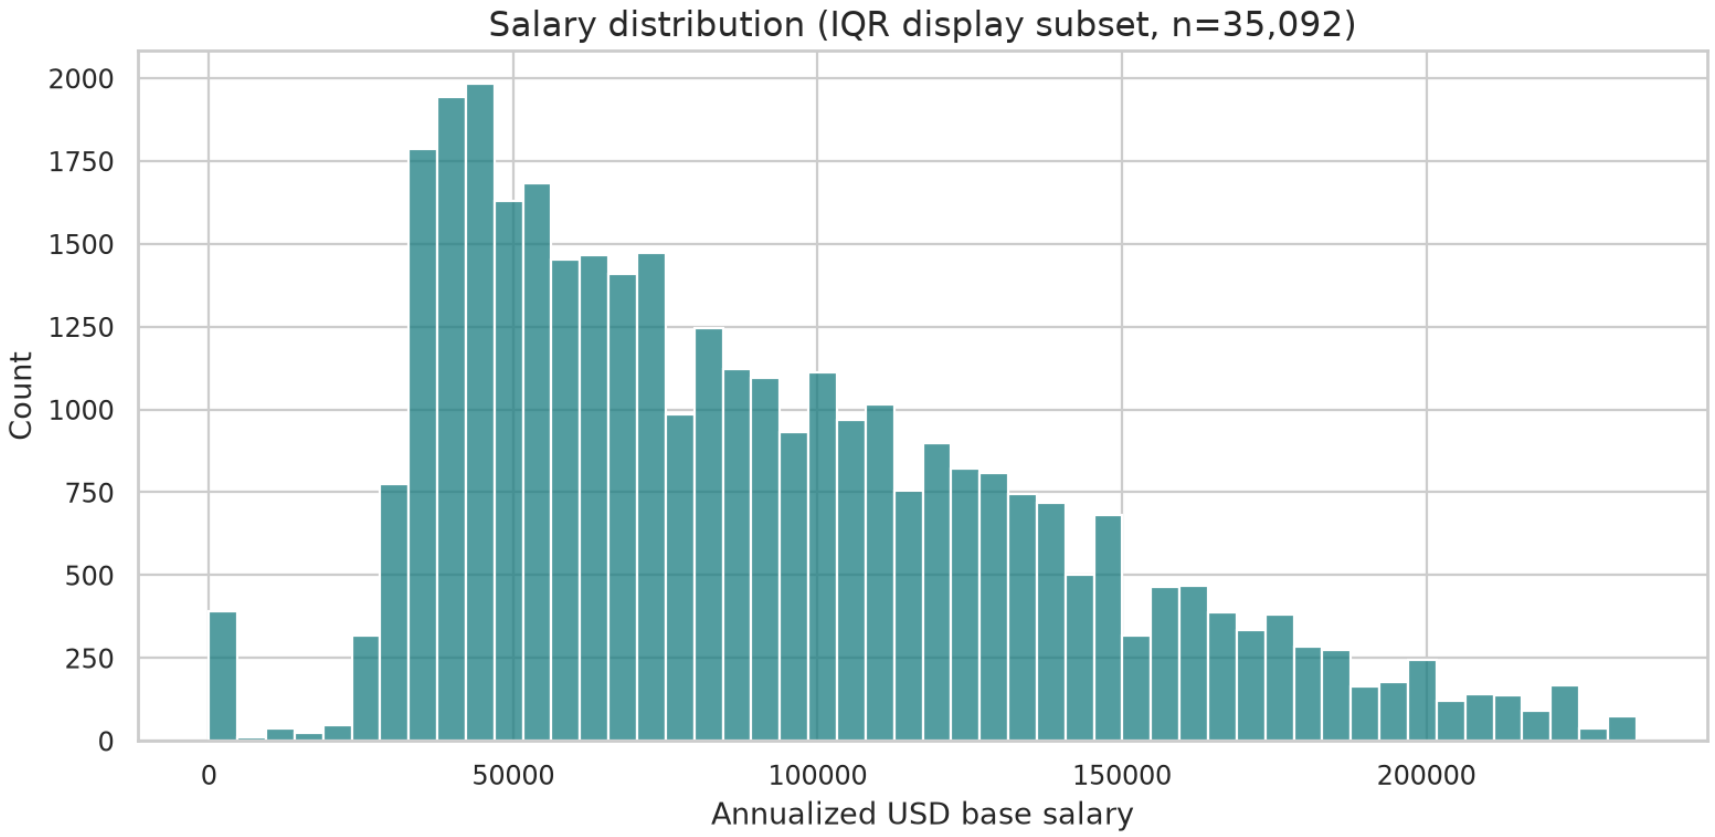

Категория определяется по названию.

Правила доступны в skills.py.

Other включает остальные профессии.

Источник: очищенная таблица jobs, title-based category. Категоризация эвристическая.

# Распределение зарплат



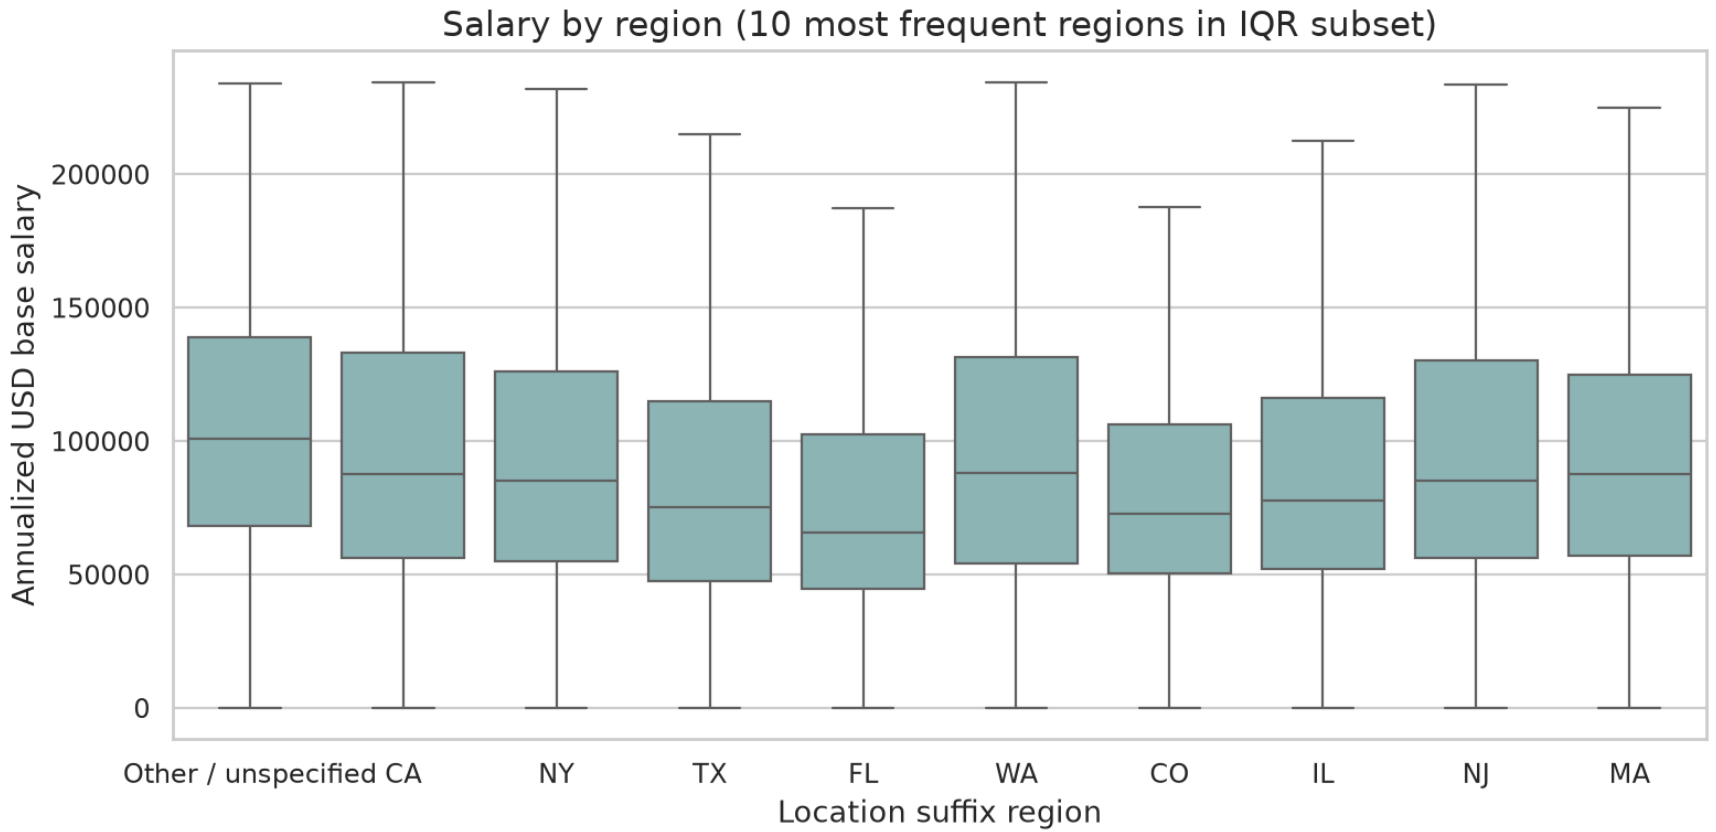

Медиана всей допустимой подвыборки **81 510 USD в год**

Покрытие 29.1%

График ограничен IQR

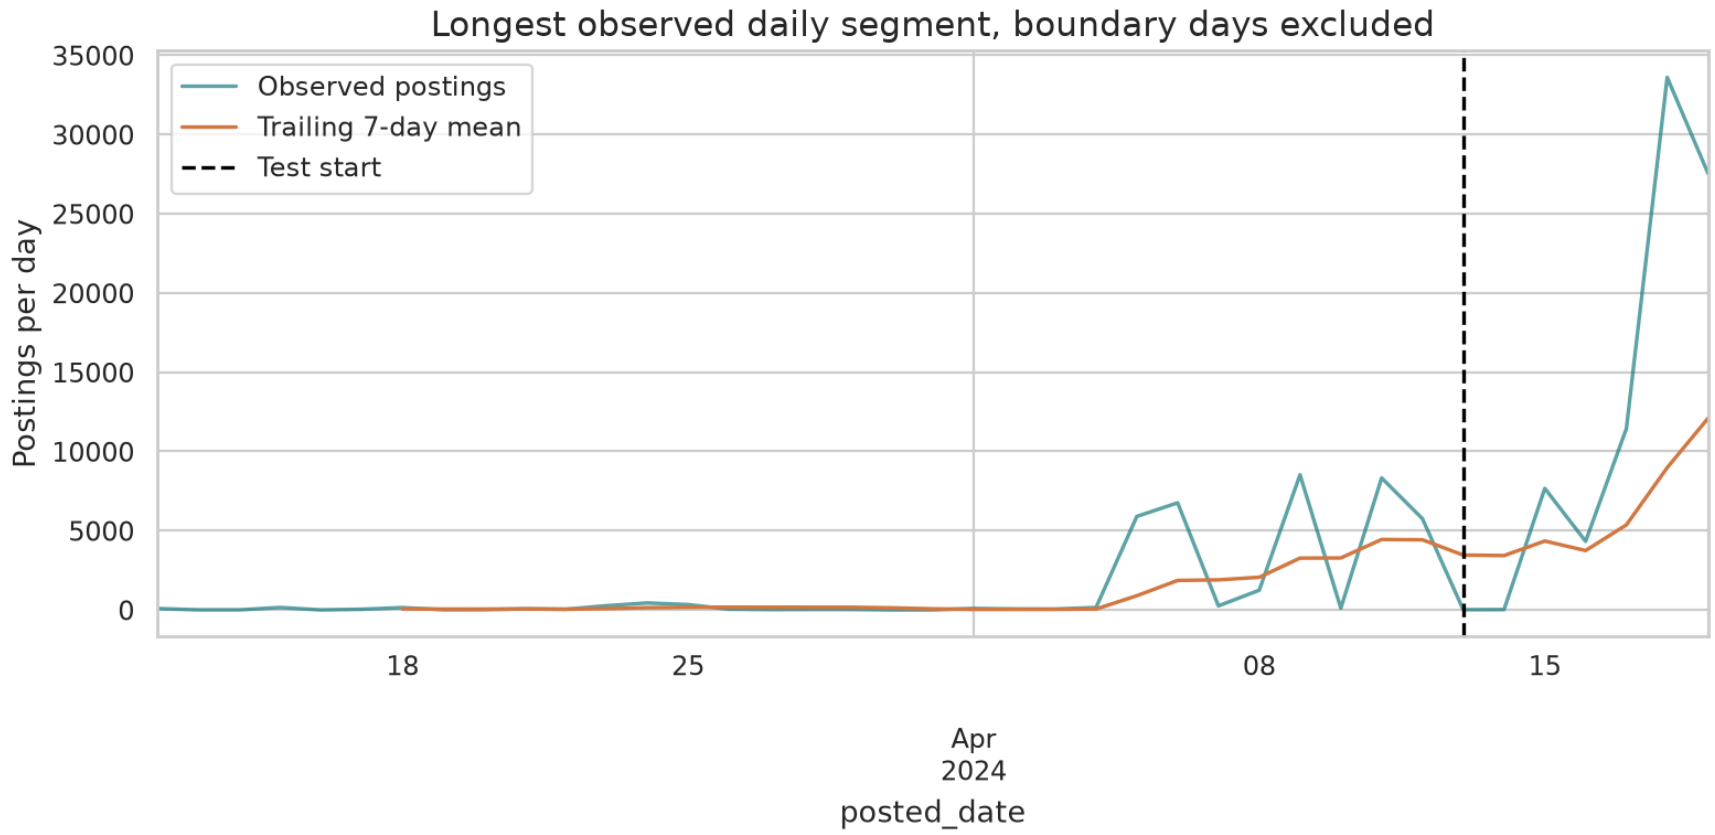
USD BASE_SALARY. Почасовая ставка × 2080. Исходные выбросы сохранены.

# Региональные различия зарплат



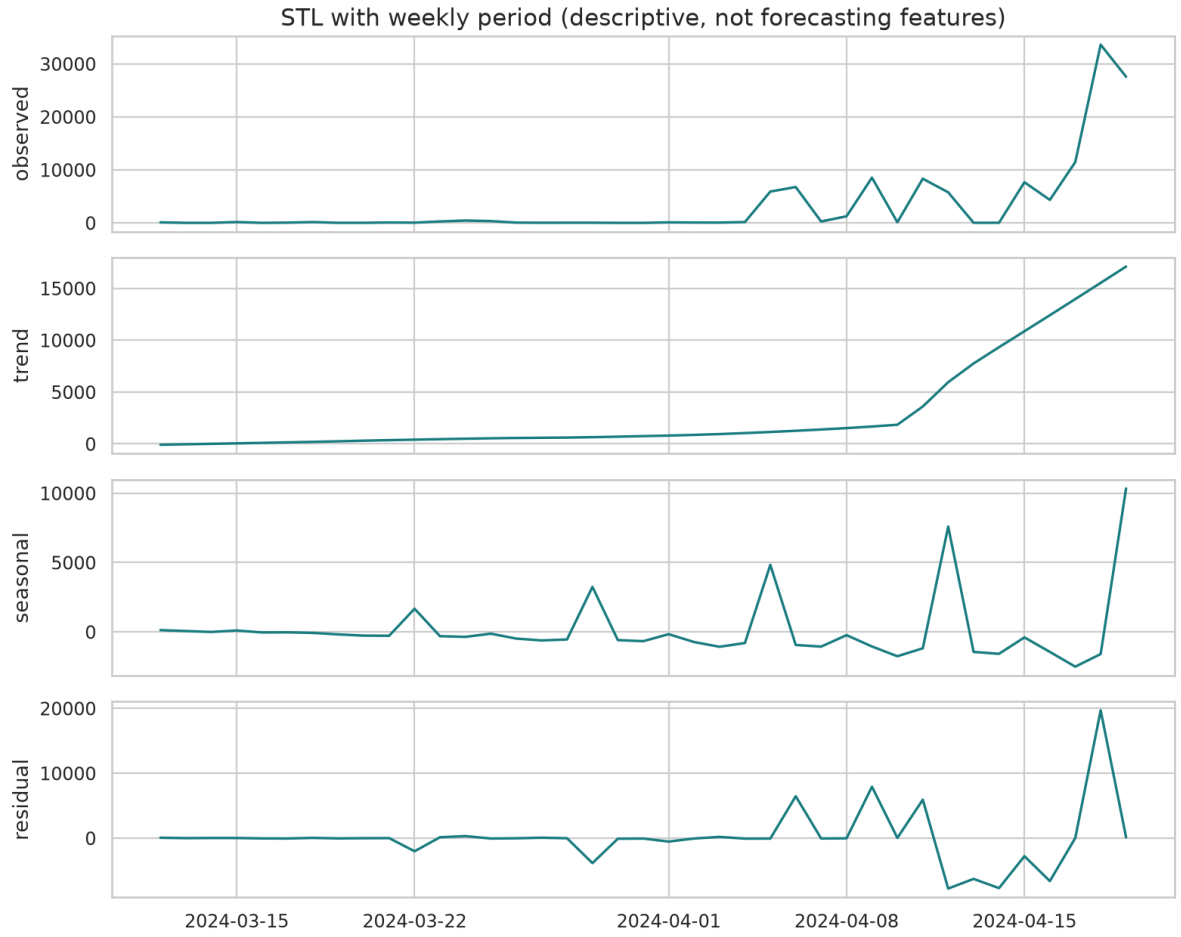

10 наиболее частых регионов IQR-подвыборки. Регион — суффикс location. Выборка зарплат неполная.

# Наблюдаемые публикации во времени




Самый длинный непрерывный сегмент, граничные дни исключены. Пропуски сбора не считаются нулём.

# Недельная декомпозиция STL




Период равен 7 дням.

Компоненты описывают этот сегмент.

STL не используется для признаков прогноза.

Источник: statsmodels STL, robust=True. Вывод о годовой сезонности не делается.

# Baseline и два метода прогноза

| Метод | MAE val | MAE test | мс | KiB |
|---|---|---|---|---|
| Naive | 4 976.14 | 7 436.86 | 0.003 | 0.44 |
| Moving average 7 | 3 443.53 | 9 516.88 | 0.017 | 1.25 |
| Linear regression | 3 518.90 | 9 042.52 | 3.412 | 13.33 |

На каждом шаге прогноз на один день.
Выбор по validation: **Moving average 7**.
На последующем тесте Naive оказался точнее.

MAE — вакансии в день. Время: медиана 5 запусков. KiB: tracemalloc, не RSS. Короткий тест ограничивает выводы.

# CSV Parquet и SQLite

| Подход | Секунды | Python MiB |
|---|---|---|
| CSV baseline | 0.1903 | 7.83 |
| Parquet | 0.0172 | 2.53 |
| SQLite + Pandas | 0.2021 | 28.08 |

Одинаковые столбцы и агрегация Pandas.
Результаты совпадают с допуском 1e-8.
Форматы решают разные задачи хранения и запросов.

Медиана 3 запусков после прогрева. Кэш ОС не очищался. Память tracemalloc не включает все нативные выделения.

# Основные результаты

Создан полный цикл анализа и база со связями.
10 SQL-запросов и фильтры помогают исследовать выборку.
Пропуски зарплат и сбора ограничивают обобщение.

Сопоставимая зарплата: 29.1% вакансий.
Медиана: 81 510 USD в год.
На тестовой неделе Naive точнее скользящего среднего.

Дальнейшая работа: ручная проверка извлечения навыков и более длинный непрерывный ряд.

# Участники и вклад в проект

**Сулейманов Тагир**
Загрузка CSV блоками, проверка качества и очистка данных, пересчёт зарплат, извлечение навыков, схема SQLite, ER-диаграмма и SQL-запросы.

**Дархан Зейнулла**
EDA и визуализации, временные ряды и STL, сравнение прогнозов по MAE, времени и памяти, дашборд Streamlit, оформление отчёта и презентации.

Совместная работа: интеграция модулей и проверка результатов.