Job Market Skills Analytics

Анализ навыков и зарплат в вакансиях LinkedIn

Итоговый проект по дисциплине Programming for Data Analysis and Database. Образовательная программа Applied Artificial Intelligence.

Сулейманов Тагир, Дархан Зейнулла

Цель и основные результаты

Проект помогает исследовать, какие навыки упоминают работодатели, как распределяются предлагаемые зарплаты и чем отличаются группы должностей и регионы. Программа объединяет загрузку данных, проверку качества, SQLite, SQL-аналитику, графики и дашборд Streamlit.

Проанализировано **123 849** уникальных вакансий. Сопоставимая зарплата доступна для **29.1%** вакансий. Медиана этой подвыборки составляет **81 510 USD в год**.

Самое частое упоминание в используемом словаре: **Communication**, 60 134 вакансий (48.55% всего набора). Это результат словарного поиска, а не оценка всех возможных навыков.

На validation выбран метод **Moving average 7**. Его MAE на последующих семи тестовых днях: **9 516.88** вакансии в день.

Данные представляют исторические снимки и зависят от процесса сбора. Выводы описывают этот набор, не весь рынок труда и не текущие вакансии. Прогноз служит учебной проверкой методов.

Полный цикл: python main.py all. Дашборд: python -m streamlit run app.py. Установка и запуск описаны в README.md.

Данные и проверка качества

Источник: Arsh Koneru, LinkedIn Job Postings (2023–2024), Kaggle, версия 13. Лицензия CC BY-SA 4.0. Входные файлы включают postings.csv, companies.csv, job_skills.csv и skills.csv. SHA-256 архива и размеры всех исходных CSV фиксируются в data/raw/manifest.json.

Показатель	Результат
Строк в postings.csv	123 849
Уникальных очищенных вакансий	123 849
Отброшено строк с неверным или повторным ID	0
Размер postings.csv	516.84 MB
Даты первоначальной публикации	2023-12-05 — 2024-04-20
Дат с наблюдениями	61
Связей вакансия и навык	372 829

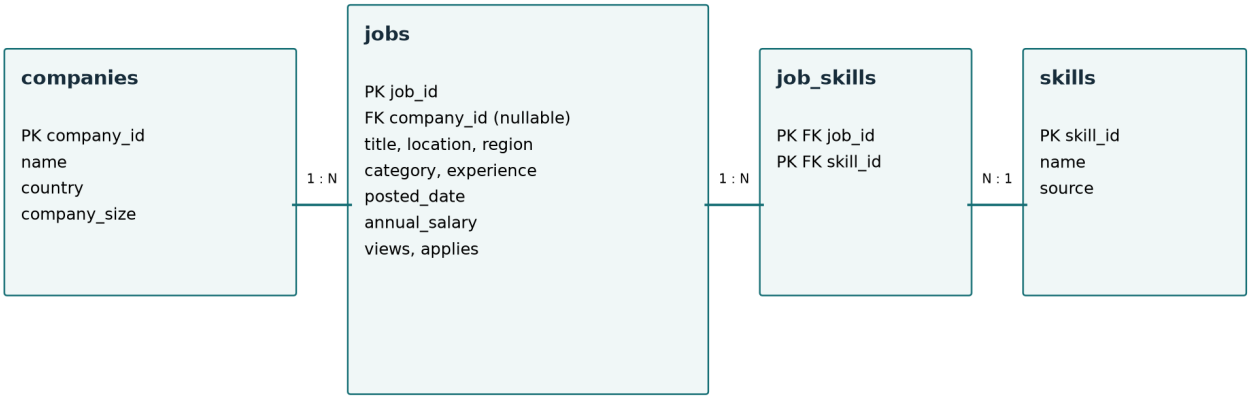
Поле источника	Пропуски %
closed_time	99.13
skills_desc	98.03
med_salary	94.93
remote_allowed	87.69
applies	81.17
max_salary	75.94
min_salary	75.94

Пропуски зарплаты не заменяются средним. Неизвестный remote_allowed не считается офисной работой. Строки без company_id сохраняются, связь с компанией допускает NULL. Если компания отсутствует в справочнике, внешний ключ становится NULL. Повторные job_id удаляются по правилу первого появления в закреплённом архиве.

Типы признаков: ID и числовые счётчики; категориальные регион, опыт и тип занятости; временная дата; исходный текст описания. Все типы и доли пропусков сохраняются в audit.json, описательная статистика — в descriptive_statistics.csv.

Архитектура и база данных

main.py управляет этапами download, build, analyze и documents. Пакет jobmarket содержит независимые модули для загрузки, очистки, извлечения навыков, SQL, прогноза и документов. app.py читает SQLite и показывает результаты с фильтрами.



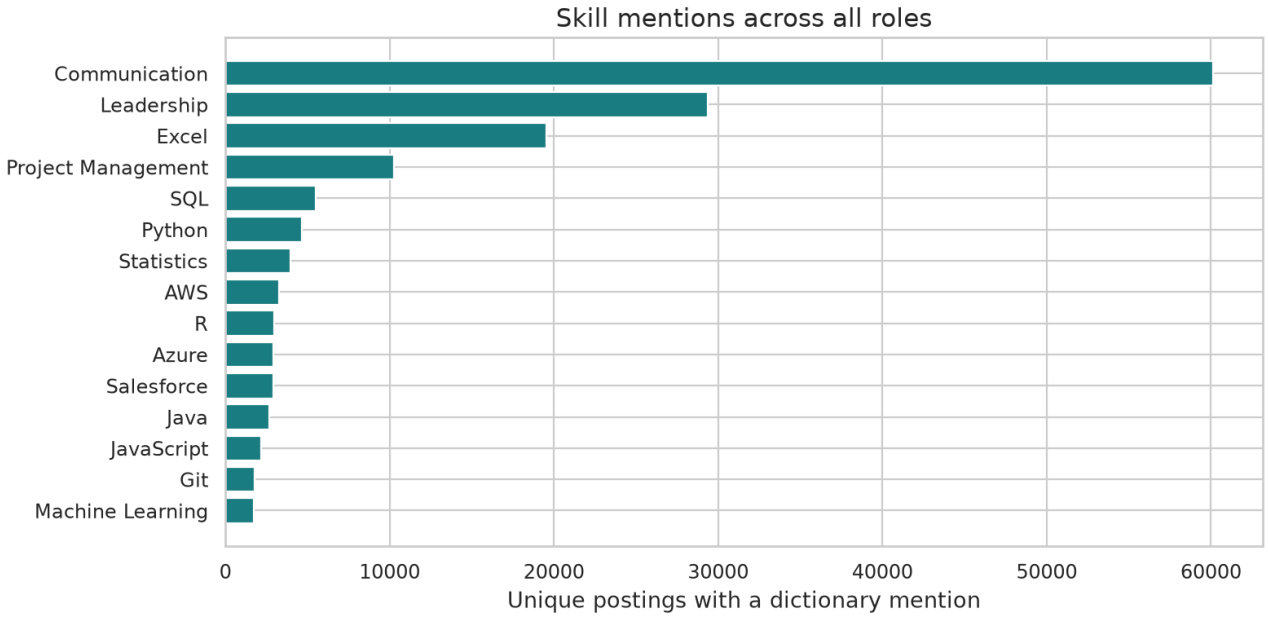
Компании связаны с вакансиями отношением один ко многим. Навыки и вакансии связаны отношением многие ко многим через job_skills. Составной первичный ключ предотвращает повтор одного навыка внутри вакансии. Префиксы platform: и dict: разделяют источники навыков.

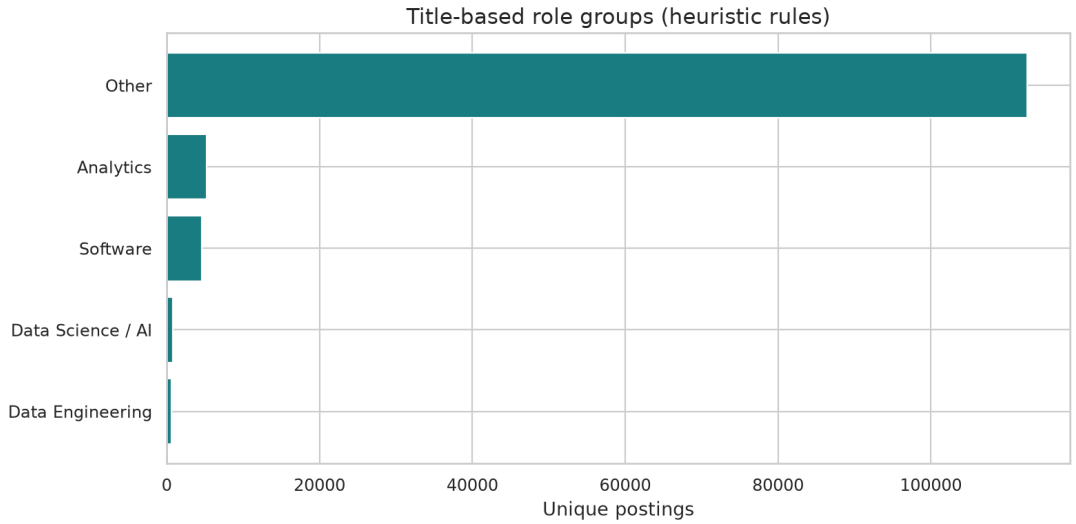
Включены внешние ключи SQLite и проверка foreign_key_check. Индексы ускоряют запросы по дате, региону, категории, компании и навыку. Зарплата, валюта и период сохраняются как атрибуты вакансии. Тексты описаний остаются в исходном архиве, аналитическая база хранит только их длину и извлечённые признаки.

Чтение postings.csv идёт блоками по 10 000 строк. Текст каждого блока обрабатывается и освобождается; компактные признаки объединяются для Parquet. Тип category сокращает повторяющиеся строки, float32 применяется к счётчикам views и applies. Оперативная память не должна вмещать весь исходный CSV, но компактная аналитическая таблица помещается в память.

Измеренное время ETL на этой машине: 310.4 с. Это локальное измерение, его нельзя переносить на другой компьютер без проверки.

Навыки и группы должностей

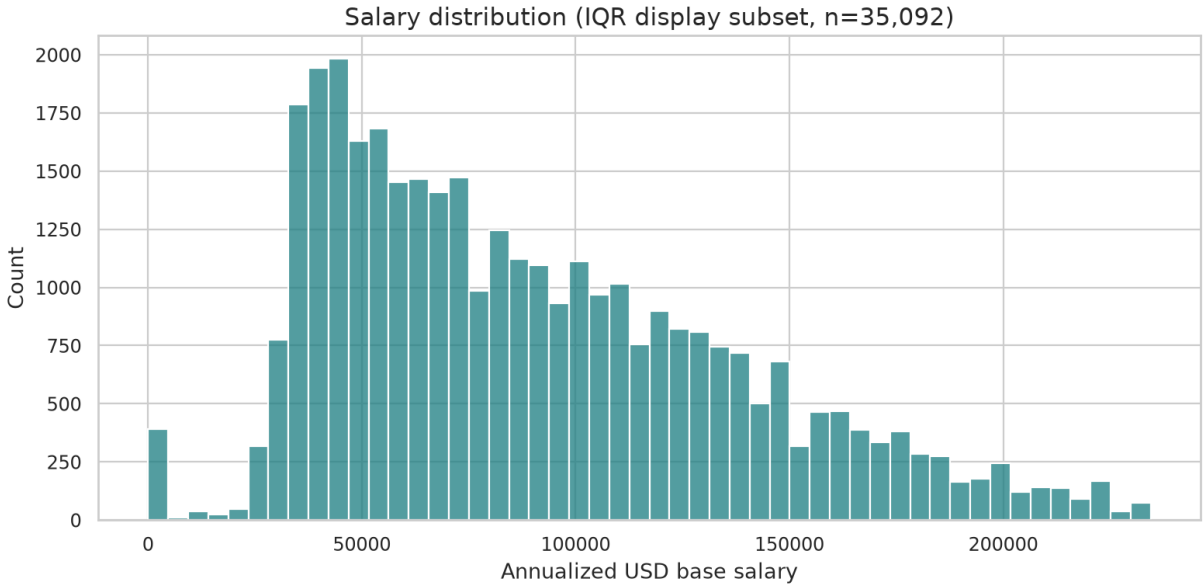


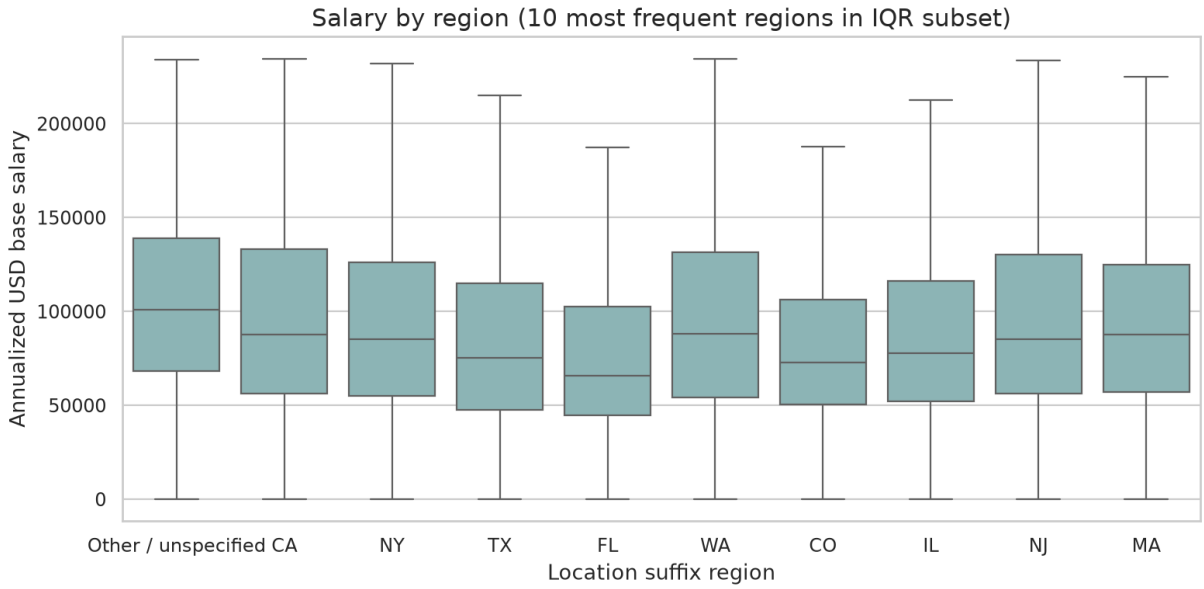


Регулярные выражения ищут 32 словарных навыка в title, description и skills_desc. Границы слов отличают Java от JavaScript, отдельно обрабатываются C++, C# и R. Один навык учитывается один раз на вакансию. Доли используют все вакансии как знаменатель и не обязаны суммироваться до 100%.

Категории должностей задаются последовательными правилами: Data Science / AI, Data Engineering, Analytics, Software, Other. Это прозрачная эвристика. Категория Other включает вакансии вне выбранных технических групп и не означает некорректные данные. Широкие функциональные категории LinkedIn показаны отдельно в SQL-таблице 02.

Зарплаты и региональные различия



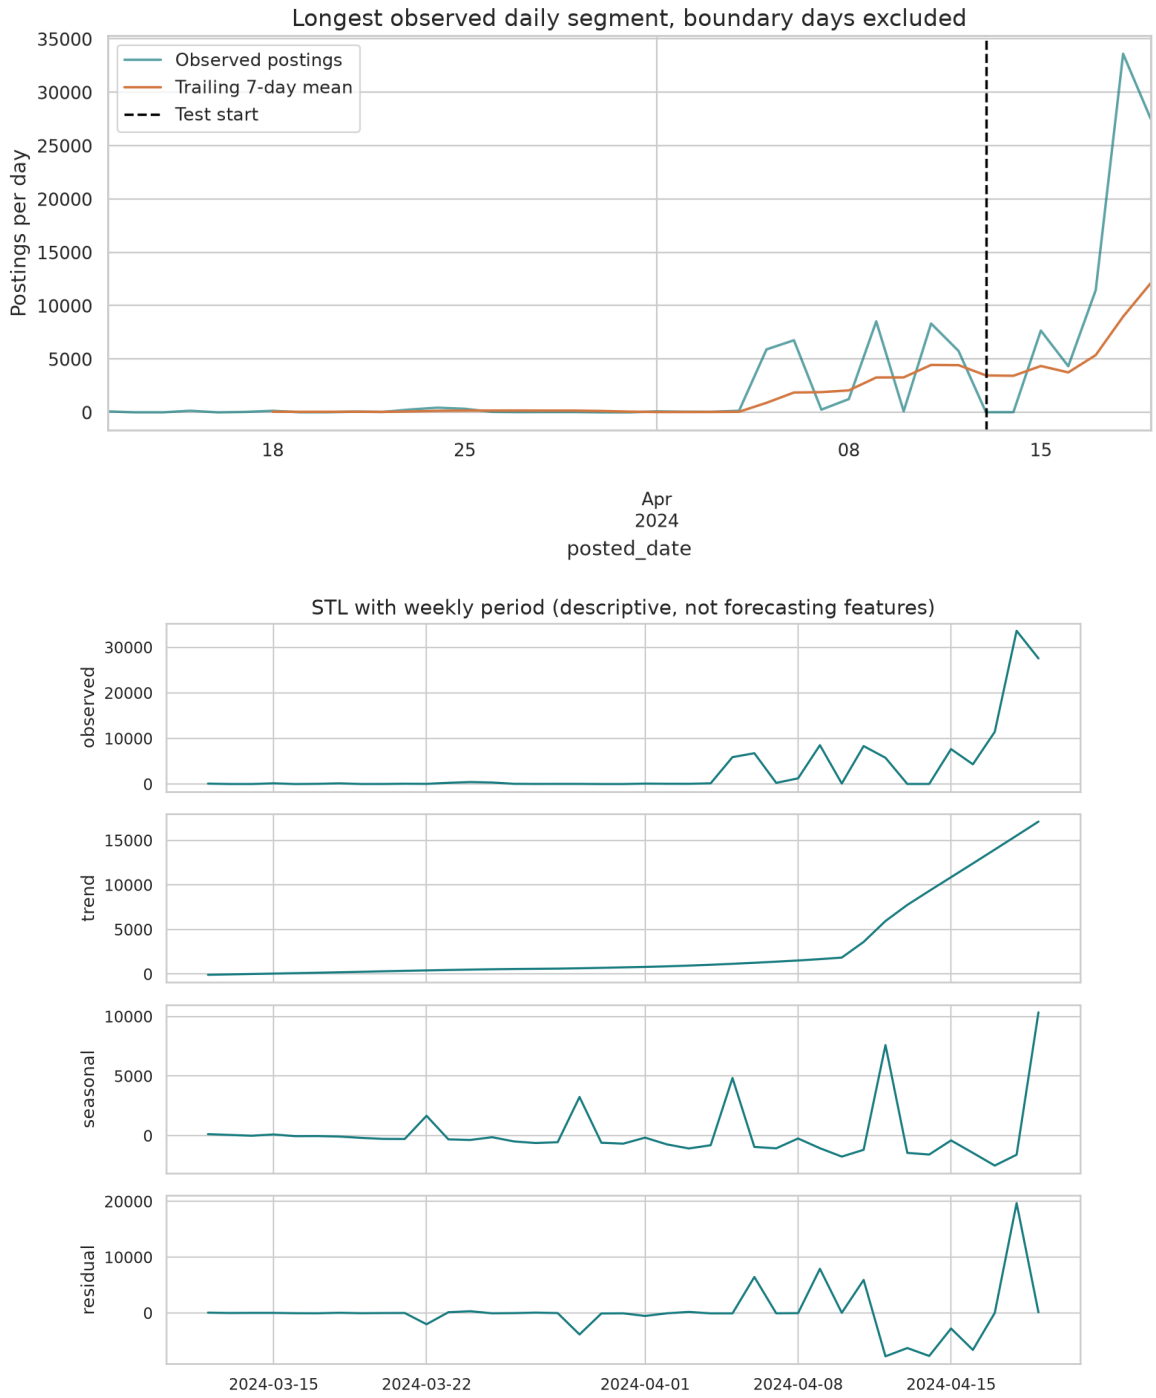


Для сопоставления используются только USD и BASE_SALARY. Положительная med_salary имеет приоритет; иначе берётся середина диапазона при наличии двух корректных границ. Коэффициенты YEARLY 1, MONTHLY 12, WEEKLY 52, BIWEEKLY 26, HOURLY 2080. Почасовой перевод предполагает 40 часов в неделю и 52 недели в год; фактическая занятость может отличаться.

IQR-границы: -57 500 и 234 500 USD. За пределами находятся 952 зарплат. На рисунках показана подвыборка n=35 092; исходные выбросы сохранены в базе и отдельном CSV. Медиана на первой странице рассчитана по всем допустимым зарплатам.

Регион определяется по двухбуквенному суффиксу location. Неоднозначные и иные форматы попадают в Other / unspecified. Геокодирование и пересчёт валют не выполняются. Различия зарплат не доказывают причинное влияние региона или навыка.

Временные ряды и сезонная декомпозиция



Для временных методов выбран самый длинный сегмент последовательных дат с наблюдениями. Первая и последняя даты сегмента исключены как потенциально неполные. Получен интервал 2024-03-12 — 2024-04-19, 39 дней. Правило выбора фиксировано до сравнения методов.

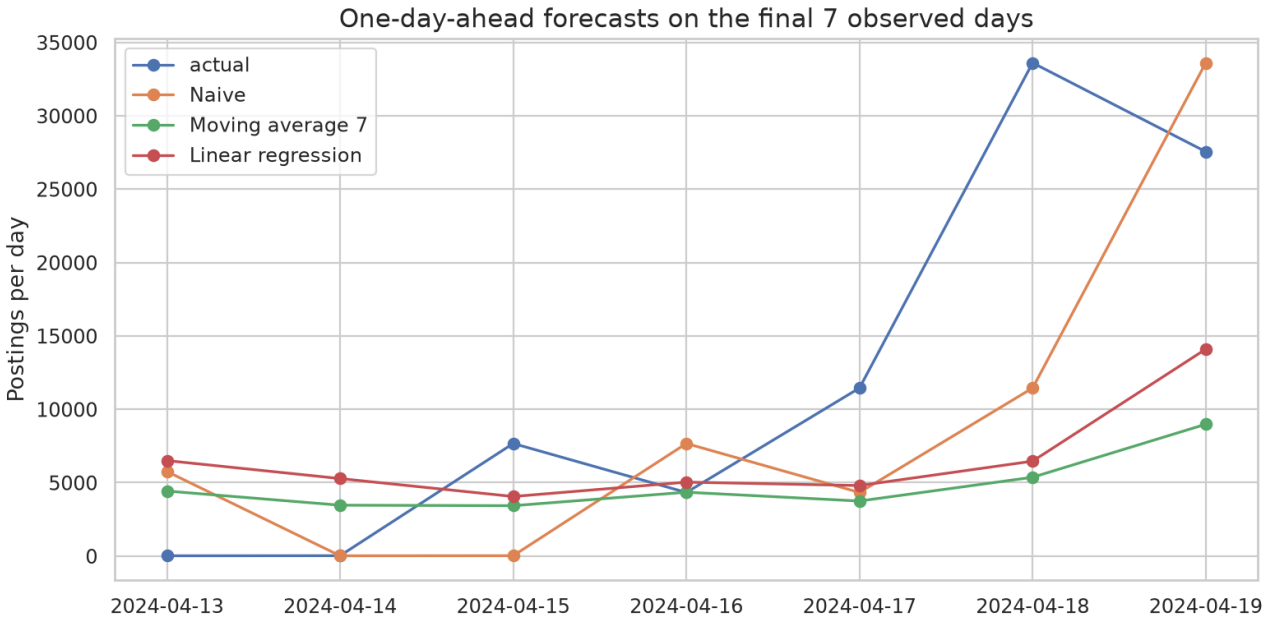
Пропущенные даты не заполняются нулём. resample формирует недельные и месячные сводки, rolling(7) — скользящее среднее. STL с периодом 7 описывает недельную структуру внутри сегмента. Она не доказывает годовую сезонность и не используется при прогнозировании. Разрывы сбора видны в интерактивной HTML-визуализации.

Сравнение методов прогноза

Начальная история: 25 дней. Validation: 7 дней с 2024-04-06. Test: 7 дней с 2024-04-13. На каждом шаге прогнозируется следующий день, затем в историю добавляется фактическое наблюдение. Это последовательный однодневный прогноз, а не прогноз сразу на неделю.

Baseline Naive повторяет последнее наблюдение. Moving average 7 усредняет последние 7 дней. Linear regression оценивает линейный тренд по последним 14 наблюдениям. Окна фиксированы заранее. Метод для итогового вывода выбирается по MAE validation; тест не участвует в выборе.

Метод	MAE val	MAE test	Время мс	Память KiB
Naive	4 976.14	7 436.86	0.003	0.44
Moving average 7	3 443.53	9 516.88	0.017	1.25
Linear regression	3 518.90	9 042.52	3.412	13.33

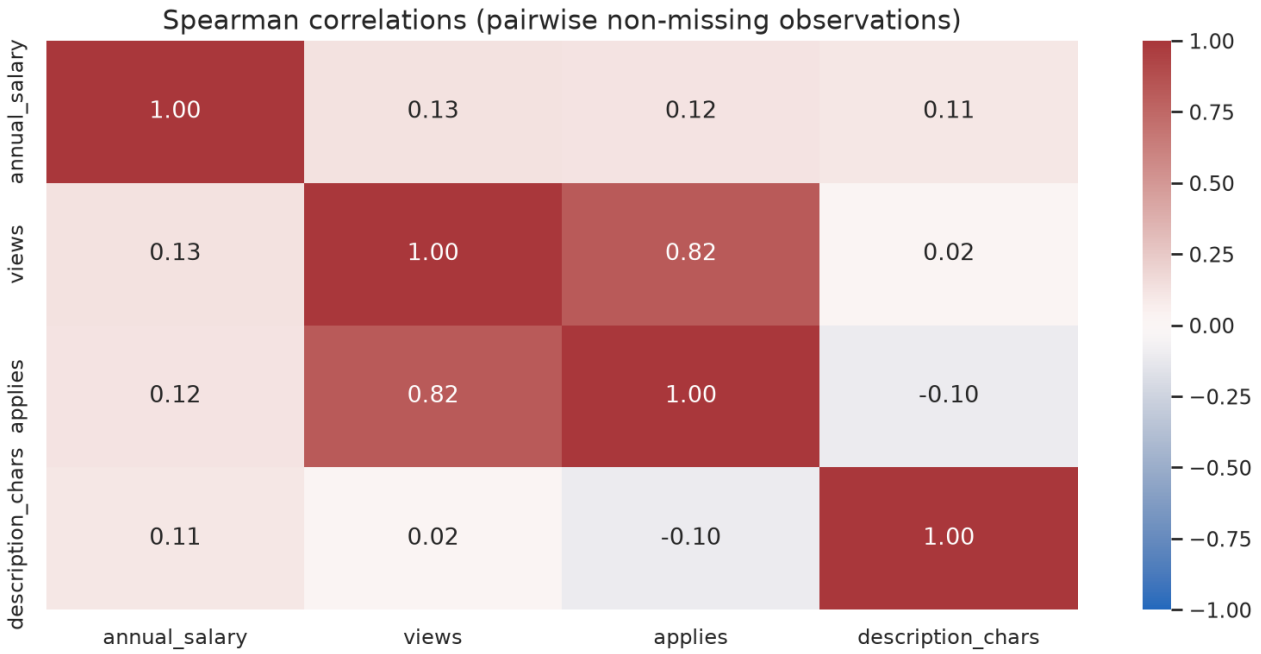


Выбор по validation: Moving average 7. Его тестовая MAE 9 516.88 означает среднюю абсолютную ошибку количества наблюдаемых вакансий за день. При таком коротком тесте нельзя заключать, что этот метод устойчиво лучше в другие периоды.

На тесте Naive точнее выбранного по validation метода: MAE 7 436.86 против 9 516.88. Значит, выигрыш на validation не перенёсся на следующую неделю. Простого baseline достаточно для этого теста; надёжность прогноза на неоднородных снимках не подтверждена.

Время — медиана пяти запусков полного тестового прохода. Память — пиковые выделения Python по tracemalloc; часть нативной памяти не учитывается, это не RSS процесса. Графики и сохранение файлов не включены в измерение.

SQL и корреляционный анализ



Используется ранговая корреляция Спирмена: зарплаты и счётчики имеют асимметричные распределения. Расчёт попарный по доступным значениям. Число наблюдений каждой пары сохранено в correlation_pair_counts.csv. Корреляция сама по себе не устанавливает причинность.

SQL	Что возвращает
01–02 JOIN и GROUP BY	Рейтинги словарных навыков и функций LinkedIn
03 GROUP BY и HAVING	Зарплаты регионов при n ≥ 100
04 JOIN	20 работодателей по числу вакансий
05 GROUP BY	Наблюдаемые дневные количества
06 CTE и ROW_NUMBER	Три самых частых названия в каждом регионе
07 CTE и JOIN	Число зарплат выше среднего своей категории
08 CTE и LAG	Месячные количества и предыдущий наблюдаемый месяц
09 JOIN и HAVING	Зарплата при упоминании навыка, n ≥ 50
10 GROUP BY	Покрытие зарплат по опыту

Все 10 запросов загружаются в Pandas через read_sql_query и сохраняются в outputs/tables. Запросы 01, 03, 05 и 10 участвуют в основных результатах. LAG сравнивает наблюдаемые месяцы; месяцы с неполным покрытием нельзя считать полноценными рыночными периодами.

Хранение и воспроизводимость

Дополнительное сравнение использует одинаковые столбцы job_id, region и annual_salary из одной очищенной таблицы. CSV является baseline, Parquet и SQLite — альтернативами. Для всех применяется одинаковая агрегация Pandas по региону. Равенство результатов проверяется с числовым допуском 1e-8.

Подход	Время с	Python MiB	Результат одинаков
CSV baseline	0.1903	7.83	Да
Parquet	0.0172	2.53	Да
SQLite + Pandas	0.2021	28.08	Да

Сумма памяти компактных блоков до оптимизации типов: 23.61 MiB, после: 12.74 MiB. Снижение: 46.0%. Это сумма memory_usage(deep=True) по блокам, а не пиковый RSS. Текст исходных описаний в это сравнение не входит.

Файл очищенной таблицы	Размер MB
CSV	16.53
Parquet zstd	3.10

Время чтения — медиана трёх запусков после прогрева; файловый кэш ОС не очищался. Python-память измеряется отдельным проходом tracemalloc. Parquet полезен для компактного обмена аналитической таблицей, SQLite — для связей и запросов дашборда. Эти измерения характеризуют выбранную операцию, а не универсальное превосходство формата.

В README приведены команды установки, загрузки версии 13, сборки и запуска. requirements.txt закрепляет проверенные версии библиотек. Тесты проверяют расчёт зарплаты, границы поиска, отсутствие утечки будущих наблюдений, разрывы календаря, внешние ключи и исполнение всех SQL-запросов.

Выводы и ограничения

Получен воспроизводимый инструмент анализа 123 849 вакансий с нормализованной базой и интерактивными фильтрами. Упоминания навыков показывают профиль требований в выбранной выборке. Зарплатные оценки относятся к 36 044 объявлениям с сопоставимой оплатой и не описывают доход всех работников.

Основные ограничения: неполное и неоднородное покрытие LinkedIn; пропуски зарплат; возможная ошибка почасового пересчёта; эвристические роли и регионы; ограниченный словарь навыков; отсутствие ручной разметки качества извлечения. Слова могут встречаться в описании работодателя или желательных требованиях. Показатель спроса означает число наблюдаемых объявлений, а не число нанятых сотрудников.

Будущие улучшения: ручная разметка независимой выборки для precision/recall извлечения, геокодирование, дедупликация похожих объявлений по тексту, более длинный непрерывный временной ряд, последовательная проверка на нескольких временных блоках. Эти улучшения в текущие результаты не включены.

Источники

https://www.kaggle.com/datasets/arshkon/linkedin-job-postings (версия 13, Arsh Koneru)

https://creativecommons.org/licenses/by-sa/4.0/

https://pandas.pydata.org/docs/

https://www.sqlite.org/lang_select.html

https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.STL.html

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

https://docs.streamlit.io/

Участники и вклад в проект

Сулейманов Тагир

Загрузка CSV блоками, проверка качества и очистка данных, пересчёт зарплат, извлечение навыков, схема SQLite, ER-диаграмма и SQL-запросы.

Дархан Зейнулла

EDA и визуализации, временные ряды и STL, сравнение прогнозов по MAE, времени и памяти, дашборд Streamlit, оформление отчёта и презентации.

Совместная работа: интеграция модулей и проверка результатов.